

Titel

Projekt-/Studien-/Bachelorarbeit

für die Prüfung zum

Bachelor of Science

des Studienganges Informatik / Angewandte Informatik

an der

Dualen Hochschule Baden-Württemberg Karlsruhe

von

Author

Abgabedatum Datum

Bearbeitungszeitraum

Matrikelnummer

Kurs

Ausbildungsfirma

Betreuer der Ausbildungsfirma

Gutachter der Studienakademie

Bearbeitungszeitraum

01234567

TINF23B5

Firma

Stadt

Betreuer

Betreuer

Erklärung

Ich versichere hiermit, dass ich meine Projekt-/Studien-/Bachelorarbeit mit dem Thema: »Titel« selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Ich versichere zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Karlsruhe, 01.01.1111

Ort

Datum

Unterschrift

Sperrvermerk

Der Inhalt dieser Arbeit darf weder als Ganzes noch in Auszügen Personen außerhalb des Prüfungsprozesses und des Evaluationsverfahrens zugänglich gemacht werden, sofern keine anderslautende Genehmigung vom Dualen Partner vorliegt.

Zusammenfassung

abstract

Inhaltsverzeichnis

Abbildungsverzeichnis	III
Tabellenverzeichnis	IV
Akürzungsverzeichnis	V
1 Einleitung	1
2 Grundlagen	3
2.1 Smart Mirrors & Ambient Intelligence	3
2.2 Raspberry Pi / Embedded Systems	3
2.3 Kontaktlose Pulsfrequenzmessung mittels Videoanalyse	3
2.3.1 Remote Photoplethysmographie (rPPG)	3
2.3.2 Eulerian Video Magnification (EVM)	10
2.3.3 Video-Ballistokardiographie (vBCG)	13
2.4 Emotionserkennung mittels Gesichtsanalyse	17
2.4.1 Bildvorverarbeitung und Gesichtserkennung	17
2.4.2 Smile-Detection als binäre Gesichtsausdruckserkennung	18
2.5 Hardwarekomponenten	19
2.6 3D Druck	19
3 Durchführung	20
3.1 Anforderungsanalyse	20
3.2 Algorithmische Konzeption	20
4 Implementierung	21
4.1 Hardwareaufbau	21
4.2 Softwareimplementierung	21
4.2.1 rPPG-Modul (Signalextraktion, Filter, Herzfrequenzberechnung)	21
4.2.2 Emotionserkennungsmodell (Pipeline, Modellwahl, Inferenz)	21

4.2.3	Backend-Logik	21
4.2.4	Frontend	21
4.3	Integration & Systemtests	21
5	Evaluation und Ergebnisse	22
5.1	Testmethodik	22
5.2	Messgenauigkeit rPPG	22
5.3	Leistung der Emotionserkennung	22
5.4	Performance des Gesamtsystems	22
5.5	Diskussion	22
6	Zusammenfassung und Ausblick	23
	Anhang	24
	Literaturverzeichnis	24

Abbildungsverzeichnis

1	Optisches Hautreflexionsmodell bei rPPG. Die Kamera erfasst eine Mischung aus spekulärer Reflexion, diffuser Reflexion und pulssynchronen Farbänderungen. ¹	4
2	Haar-like Features	18

¹Vgl. WANG, W. u. a. (2017), S. 2

Tabellenverzeichnis

Abkürzungsverzeichnis

ROI Region of Interest

1. Einleitung

Motivation

Im Zuge der fortschreitenden Digitalisierung ist ein zunehmendes Interesse privater Haushalte an einer effizienteren Nutzung ihrer Wohnflächen festzustellen.² Es lässt sich ein signifikanter Anstieg der Nutzung von Smart-Home-Technologien feststellen.³ Der Einsatz intelligenter Technologien erstreckt sich von Haushaltsgeräten bis hin zu Systemen zur Steuerung von Heizungsanlagen.⁴ Ein besonderer Fokus liegt auf dem Bereich der Gesundheits- und Pflegeversorgung, in dem der höchste Anstieg zu verzeichnen ist.⁵

Mit der Zunahme vernetzter Systeme steigt jedoch auch die Komplexität ihrer Bedienung.⁶ Die Interaktion mit den Systemen erfolgt durch die Nutzer mittels Smartphones, Tablets, Smartwatches oder ähnlicher Geräte. In Verbindung mit der technischen Weiterentwicklung erfährt auch das Gesundheitsbewusstsein eine zunehmende Relevanz. Wearables, Fitness-Tracker und Apps zur Schlaf- oder Stressanalyse legen nahe, dass Nutzer ein verstärktes Interesse daran haben, physiologische Parameter wie Herzfrequenz oder Stresslevel zu erfassen und auszuwerten.⁷

Das Konzept des Smart Mirrors greift genau diese Problematik auf. Der Spiegel ist ein alltäglicher Gebrauchsgegenstand, der von der technischen Affinität des Nutzers unabhängig ist. Die Integration digitaler Anzeigen sowie Sensortechnologien führt zur Transformation des Smart Mirrors zu einer natürlichen Mensch-Maschine-Schnittstelle. Die Visualisierung meteorologischer Informationen stellt eine Möglichkeit dar, relevante Informationen auf anschauliche Weise darzustellen. Des Weiteren besteht mittels der Sensortechnologie die Möglichkeit, Vitalwerte zu messen und somit einen Beitrag zur Unterstützung im Gesund-

²Vgl. PFNÜR, A. u. a. (2023), S. 4

³Vgl. ebenda S. 4

⁴Vgl. ebenda S. 4

⁵Vgl. ebenda S. 4

⁶Vgl. FU, K. u. a. S. 2 (Vom Autor übersetzt)

⁷Vgl. SHEI, R.-J. u. a. (2022), S. 1975–1976 (Vom Autor übersetzt)

heitsbereich zu leisten. Die kontaktlose Messung des Pulses oder der Emotionen ermöglicht dem Nutzer die Erfassung sämtlicher Informationen in einer übersichtlichen Darstellung.

Der Smart Mirror vereint somit zwei zentrale Entwicklungen: die zunehmende Vernetzung des Wohnraums und den Trend zur personalisierten Gesundheitsüberwachung. Das Gerät fungiert nicht lediglich als Informationsdisplay, sondern als adaptives Assistenzsystem, das digitale Infrastruktur mit individuellen Gesundheitsdaten verknüpft.

Zielsetzung und Forschungsfragen

Das Ziel dieser wissenschaftlichen Arbeit, ist die Entwicklung und Evaluation eines Smart Mirrors, welcher in der Lage ist, Informationen wie das Wetter oder den per Kamera gemessenen Puls eines Nutzer anzuzeigen.

Durch diese Zielsetzung der Arbeit ergeben sich folgende Forschungsfragen:

- i. Mit welcher Genauigkeit kann die Herzfrequenz mittels einer Industriekamera gemessenen werden?
- ii. Welche Einflussfaktoren wirken sich signifikant auf die Messqualität aus?
- iii. Wie kann ein Smart-Mirror-System konzipiert und realisiert werden, das kontaktlose Vital- und Emotionserkennung zuverlässig, performant und benutzerfreundlich in einem Alltagsobjekt integriert?
- iv. Inwiefern eignet sich ein Smart Mirror als Plattform für die kontaktlose Erfassung und Verarbeitung sensibler biometrischer Daten im häuslichen Umfeld?

2. Grundlagen

2.1 Smart Mirrors & Ambient Intelligence

2.2 Raspberry Pi / Embedded Systems

2.3 Kontaktlose Pulsfrequenzmessung mittels Videoanalyse

Die kontaktlose Erfassung des Pulses mittels Standard-Kamerasystemen basiert auf der Extraktion sehr kleiner Vitalsignale, die durch den Herzzyklus entstehen. Im Gegensatz zu klassischen Verfahren, die direkten Hautkontakt erfordern, nutzt die videobasierte Analyse zwei unterschiedliche physikalische Effekte: einerseits die Farbveränderung der Hautoberfläche durch den Blutfluss⁸ und zum anderen die leichten Bewegungen des Körpers als Reaktion auf einen Herzschlag.⁹

Im Folgenden werden zunächst die beiden Messprinzipien, die Remote-Photoplethysmographie (rPPG) und die Videoballistokardiographie (vBCG), erläutert. Ergänzend wird die Eulerian Video Magnification (EVM) beschrieben, da sie kein eigenständiges Messprinzip darstellt, sondern als Signalverarbeitungsmethode zur Verstärkung kleiner Farb- oder Bewegungsänderungen in Videos eingesetzt werden kann.¹⁰

2.3.1 Remote Photoplethysmographie (rPPG)

Remote-Photoplethysmographie (rPPG) ist ein kontaktloses Verfahren zur Überwachung kardiovaskulärer Aktivitäten, wie beispielsweise dem Puls.¹¹ Für dieses Verfahren können handelsübliche RGB-Kameras verwendet werden, wobei normales Umgebungslicht in der Regel als Lichtquelle ausreicht.

⁸Vgl. LEE, R. J./ SIVAKUMAR, S./ LIM, K. H. (2023), S. 44700

⁹Vgl. KIM, C.-S. u. a. (2016), S. 1

¹⁰Vgl. WU, H.-Y. u. a. S. 1

¹¹Vgl. WANG, W. u. a. (2017), S. 2

Physiologische und optische Grundlagen

Beim rPPG-Verfahren werden die optischen Eigenschaften des menschlichen Blutes genutzt. Der farbgebende und sauerstofftransportierende Bestandteil des Blutes, das sogenannte Hämoglobin, wirkt im Gewebe wie ein optischer Filter.¹² Dieser Blutfarbstoff absorbiert grünes und gelbes Licht besonders stark, während rotes Licht stärker reflektiert wird.¹³




Abbildung 1: Optisches Hautreflexionsmodell bei rPPG. Die Kamera erfasst eine Mischung aus spekulärer Reflexion, diffuser Reflexion und pulssynchronen Farbänderungen.¹⁴

Mit jedem Herzschlag verändert sich das Blutvolumen und damit auch die optische Absorption in den Blutgefäßen der oberen Hautschicht. Da Blut Licht stärker absorbiert als das umliegende Gewebe, führt diese pulssynchrone Volumenänderung zu geringen Änderungen der reflektierten Lichtintensität. Diese Intensitätsschwankungen sind für das menschliche Auge kaum wahrnehmbar, können jedoch von einer Kamera erfasst und anschließend als plethysmographisches Pulssignal, also als optisch gemessene Darstellung der pulssynchronen Blutvolumenänderung, extrahiert werden.¹⁵ Besonders deutlich treten diese Signalanteile im grünen Farbkanal hervor, da dieser mit einem Absorptionsmaximum von Hämoglobin zusammenhängt und in den Untersuchungen von Verkruysse et al. das stärkste plethysmographische Signal lieferte.¹⁶

¹²Vgl. WANG, W. u. a. (2017), S. 2

¹³Vgl. VERKRUYSSE, W./ SVAASAND, L. O./ NELSON, J. S. (2008), S. 21440

¹⁵Vgl. ebenda S. 44700

¹⁶Vgl. ebenda S. 21434

Obwohl der grüne Farbkanal in der Regel das stärkste plethysmographische Signal liefert, enthalten auch der rote und der blaue Farbkanal pulssynchrone Informationen. Diese zusätzlichen Farbkanäle sind insbesondere für algorithmische Verfahren relevant, da sie komplementäre Informationen über Hautreflexion, Beleuchtungseinflüsse und Bewegungsartefakte bereitstellen.¹⁷

Der Grund hierfür liegt in der unterschiedlichen Zusammensetzung der gemessenen RGB-Signale: Neben den pulssynchronen Farbänderungen enthalten sie auch nicht-physiologische Signalanteile, etwa durch Beleuchtungsschwankungen, Reflexionen oder Bewegungen zwischen Haut, Lichtquelle und Kamera. Während solche Störungen häufig mehrere Farbkanäle gleichzeitig beeinflussen, besitzt das eigentliche Pulssignal aufgrund der wellenlängenabhängigen Lichtabsorption eine charakteristische Verteilung über die RGB-Kanäle. Moderne rPPG-Algorithmen nutzen diese Unterschiede, indem sie die Farbkanäle mathematisch kombinieren. Dadurch können gemeinsame Störanteile reduziert und das pulssynchrone Signal stabiler extrahiert werden.¹⁸

Algorithmische Signalverarbeitung

Um aus den kaum sichtbaren Farbveränderungen der Hautoberfläche einen konkreten Messwert zu ermitteln, durchläuft das Videomaterial eine mehrstufige algorithmische Verarbeitungspipeline. Diese lässt sich in die folgenden Schritte unterteilen:

1. Region of Interest (ROI) und Tracking Im ersten Schritt muss die Hautregion, in der die Messung stattfinden soll, im Video bestimmt werden. Da nicht das gesamte Bild relevante Informationen enthält, wird eine sogenannte Region of Interest (ROI) definiert. In klassischen rPPG-Verfahren kommt hierfür häufig der Viola-Jones-Algorithmus zur Gesichtserkennung zum Einsatz.¹⁹ Um zu verhindern, dass bei leichten Kopfbewegungen in jedem Frame eine rechenintensive Neuerkennung des Gesichts durchgeführt werden muss und um

¹⁷Vgl. ebenda S. 21434

¹⁸Vgl. WANG, W. u. a. (2017), S. 1–3

¹⁹Vgl. LEE, R. J./ SIVAKUMAR, S./ LIM, K. H. (2023), S. 44705

Bewegungsartefakte zu minimieren, wird die ROI häufig mit Feature-Tracking-Algorithmen, wie dem Kanade-Lucas-Tomasi-Tracker (KLT), über die Zeit verfolgt.²⁰

2. Räumliche Mittelwertbildung (Spatial Pooling) Da das pulssynchrone optische Signal sehr schwach ist und häufig im Kamerarauschen untergeht, werden die RGB-Pixelwerte innerhalb der ROI für jeden einzelnen Videoframe räumlich gemittelt. Durch diese Mittelwertbildung wird das Sensorrauschen reduziert und es entstehen drei eindimensionale Rohsignale für den roten, grünen und blauen Farbkanal über die Zeit.²¹

3. Zeitliche Filterung (Temporal Filtering) Die extrahierten RGB-Rohsignale enthalten neben dem Pulssignal auch störende Signalanteile. Diese können beispielsweise durch langsame Haltungsänderungen, Bewegungen oder das Flackern künstlicher Lichtquellen entstehen. Durch die Anwendung eines zeitlichen Bandpassfilters werden Signalanteile außerhalb des menschlichen Pulsbereichs reduziert. In der Regel wird hierfür ein Frequenzbereich von etwa 0,75 bis 4 Hz gewählt, was ungefähr einem Pulsbereich von 45 bis 240 Schlägen pro Minute entspricht.²² Zur weiteren Signaloptimierung werden häufig zusätzlich Detrending, Normalisierung und Glättung eingesetzt. Dabei entfernt Detrending langsame Signalverschiebungen, die Normalisierung bringt die Farbkanäle auf ein vergleichbares Skalenniveau und die Glättung reduziert kurzzeitige zufällige Schwankungen im Signal.²³

4. Signal-Extraktion (Color Space Projection) Der kritischste Schritt der rPPG-Pipeline ist die Trennung des eigentlichen Pulssignals von überlagernden Störungen, wie beispielsweise Spiegelungen oder Intensitätsschwankungen durch Bewegungen.²⁴ Um zu verstehen, wie Algorithmen diese Trennung vornehmen, wird das optische Hautreflexionsmodell betrachtet. Das von der Kamera nach der räumlichen Mittelwertbildung (Spatial Pooling)

²⁰Vgl. ebenda S. 44705

²¹Vgl. WANG, W. u. a. (2017), S. 2

²²Vgl. LEE, R. J./ SIVAKUMAR, S./ LIM, K. H. (2023), S. 44707

²³Vgl. LEE, R. J./ SIVAKUMAR, S./ LIM, K. H. (2023), S. 44707

²⁴Vgl. WANG, W. u. a. (2017), S. 2

erfasste RGB-Signal $C(t)$ lässt sich als lineare Mischung aus verschiedenen Komponenten approximieren:²⁵

$$C(t) \approx \mathbf{u}_c \cdot I_0 \cdot c_0 + \mathbf{u}_c \cdot I_0 \cdot c_0 \cdot i(t) + \mathbf{u}_s \cdot I_0 \cdot s(t) + \mathbf{u}_p \cdot I_0 \cdot p(t) \quad (2.1)$$

Hierbei steht $\mathbf{u}_c \cdot I_0 \cdot c_0$ für die stationäre Hautreflexion, also den konstanten Hautton. Die zeitlich veränderlichen Störkomponenten setzen sich aus den relativen Intensitätsschwankungen $i(t)$ und den Reflexionen $s(t)$ zusammen. Das gesuchte Nutzsignal, also die durch das pulsierende Blutvolumen verursachte Farbänderung, wird durch $p(t)$ dargestellt, wobei der Vektor $\mathbf{u}_p$ die relative Stärke des Pulses in den jeweiligen Farbkanälen angibt.²⁶

Aus dem Modell wird deutlich, dass das von der Kamera erfasste RGB-Signal nicht direkt dem gesuchten Pulssignal entspricht, sondern aus mehreren überlagerten Anteilen besteht. Für die rPPG-Signalverarbeitung ergibt sich daraus die Aufgabe, die pulssynchrone Komponente $p(t)$ möglichst robust von Beleuchtungs-, Reflexions- und Bewegungsanteilen zu trennen.²⁷ In der Literatur lassen sich hierfür insbesondere zwei grundlegende Verfahrensrichtungen unterscheiden:

- **Blind Source Separation (BSS):** Frühe rPPG-Ansätze nutzten Verfahren der Blind Source Separation, beispielsweise die Hauptkomponentenanalyse (Principal Component Analysis, PCA) oder die Independent Component Analysis (ICA), um das gemessene RGB-Signal statistisch in mehrere Signalanteile zu zerlegen. Der allgemeine Prozess dieser Methoden lässt sich durch folgende Gleichung beschreiben:

$$Y(t) = W \cdot C(t) \quad (2.2)$$

Dabei beschreibt $C(t)$ das beobachtete RGB-Signal der Kamera, während $Y(t)$ die

²⁵Vgl. WANG, W. u. a. (2017), S. 2

²⁶Vgl. WANG, W. u. a. (2017), S. 2

²⁷Vgl. WANG, W. u. a. (2017), S. 2

daraus berechneten Quellsignale enthält. Diese Komponenten können sowohl pulssynchrone Signalanteile als auch Störanteile umfassen. Die Matrix W wird als Entmischungsmatrix bezeichnet und bestimmt, wie die RGB-Signale kombiniert werden. PCA und ICA unterscheiden sich vor allem darin, nach welchem Kriterium diese Matrix bestimmt wird. Während PCA auf der Kovarianz der RGB-Signale basiert und unkorrelierte Komponenten erzeugt, geht ICA von statistisch unabhängigen und nicht gaußförmig verteilten Quellsignalen aus.²⁸

Ein Nachteil dieser Verfahren ist, dass sie „blind“ arbeiten und somit kein Vorwissen über die Reflexionseigenschaften der Haut nutzen. Dadurch können sie besonders bei periodischen Bewegungen an ihre Grenzen stoßen, da solche Bewegungsartefakte ebenfalls periodische Signalanteile erzeugen und damit schwer vom eigentlichen Pulssignal zu unterscheiden sind.²⁹

- **Modellbasierte Verfahren:** Modellbasierte Verfahren nutzen gezielt Annahmen über die optischen und physiologischen Eigenschaften der Haut und des Blutes. Der CHROM-Algorithmus arbeitet mit Chrominanzsignalen, also Farbsignalen, bei denen die reine Helligkeitsinformation weitgehend ausgeblendet wird.³⁰ Ein weiterer modellbasierter Ansatz ist das POS-Verfahren (Plane-Orthogonal-to-Skin). Dabei werden die zeitlich normalisierten RGB-Signale (R_n, G_n, B_n) auf eine Ebene projiziert, die orthogonal zum Hautfarbvektor im normalisierten RGB-Raum liegt. Auf diese Weise sollen gemeinsame Intensitätsschwankungen abgeschwächt werden, während pulssynchrone Farbänderungen stärker hervortreten.

Diese Projektion erzeugt zwei Zwischensignale $S_1(t)$ und $S_2(t)$, die aus den zeitlich normalisierten Farbkanälen gebildet werden:

$$S_1(t) = G_n(t) - B_n(t) \quad (2.3)$$

²⁸Vgl. WANG, W. u. a. (2017), S. 3

²⁹Vgl. WANG, W. u. a. (2017), S. 3

³⁰Vgl. WANG, W. u. a. (2017), S. 4

$$S_2(t) = G_n(t) + B_n(t) - 2R_n(t) \quad (2.4)$$

Die beiden Signale werden anschließend durch das sogenannte Alpha-Tuning zu einem geschätzten Pulssignal $\hat{p}(t)$ kombiniert. Dabei wird $S_2(t)$ mit dem Faktor α skaliert, wobei α aus dem Verhältnis der Standardabweichungen beider Zwischensignale berechnet wird:³¹

$$\hat{p}(t) = S_1(t) + \alpha \cdot S_2(t) \quad \text{mit} \quad \alpha = \frac{\sigma(S_1)}{\sigma(S_2)} \quad (2.5)$$

Da die projizierten Signale $S_1(t)$ und $S_2(t)$ unterschiedliche Anteile von Pulssignal und Störsignalen enthalten, kann die skalierte Addition dazu beitragen, Bewegungs- und Intensitätsartefakte zu reduzieren. Gleichzeitig bleibt die pulssynchrone Farbänderung erhalten und kann robuster als Pulssignal geschätzt werden.³²

Das aus der Signalextraktion gewonnene eindimensionale Zeitsignal wird abschließend genutzt, um die Pulsfrequenz zu bestimmen. Dies geschieht entweder im Zeitbereich durch Peak-Detection oder im Frequenzbereich mithilfe einer Fast-Fourier-Transformation (FFT). Bei der Peak-Detection werden lokale Maxima des Signals erkannt und als einzelne Herzschläge interpretiert. Die FFT zerlegt das Zeitsignal dagegen in seine Frequenzanteile, sodass die dominante periodische Komponente des Signals bestimmt werden kann. Diese dominante Frequenz entspricht der geschätzten Pulsfrequenz.

Bei der Analyse im Frequenzbereich wird das extrahierte rPPG-Signal vom Zeitbereich in den Frequenzbereich überführt. Häufig wird hierfür das Welch-Verfahren genutzt, um die spektrale Leistungsdichte (Power Spectral Density, PSD) des Signals zu schätzen. Die Frequenz f_{rPPG} , bei der die PSD ihr Maximum innerhalb des menschlichen Pulsbereichs erreicht, wird als dominante Pulsfrequenz interpretiert. Der finale Messwert in Schlägen pro

³¹Vgl. WANG, W. u. a. (2017), S. 6–7

³²Vgl. WANG, W. u. a. (2017), S. 6

Minute ergibt sich anschließend durch Multiplikation dieser Frequenz mit 60:³³

$$HR_{estimated} = 60 \cdot f_{rPPG} \quad (2.6)$$

2.3.2 Eulerian Video Magnification (EVM)

Während die zuvor beschriebene rPPG-Pipeline (Abschnitt 2.3.1) darauf abzielt, aus den Farbveränderungen eines Videos ein eindimensionales Pulssignal zu extrahieren, dient die *Eulerian Video Magnification* (EVM) primär der Verstärkung kleiner zeitlicher Veränderungen in Videosequenzen. EVM ist damit kein eigenständiges Verfahren zur Berechnung der Pulsfrequenz, sondern eine Signalverarbeitungsmethode, mit der sehr kleine Farb- oder Bewegungsänderungen sichtbar gemacht oder für eine nachgelagerte Analyse hervorgehoben werden können.³⁴

Die EVM-Verarbeitungspipeline

Der EVM-Algorithmus kombiniert räumliche und zeitliche Signalverarbeitung und lässt sich in vier wesentliche Schritte unterteilen:³⁵

1. **Räumliche Zerlegung:** Zunächst wird jedes Einzelbild des Videos mithilfe einer Laplace-Pyramide in mehrere räumliche Frequenzbänder zerlegt. Dabei entstehen verschiedene Versionen des Bildes, die jeweils unterschiedliche Detailstufen enthalten: niedrige Frequenzbänder beschreiben grobe, flächige Bildbereiche, während höhere Frequenzbänder feine Details und Kanten enthalten. Dadurch können subtile Farb- oder Bewegungsänderungen je nach Bildstruktur getrennt verarbeitet und unterschiedlich stark verstärkt werden.
2. **Zeitliche Filterung:** Anschließend wird auf jedes räumliche Frequenzband ein zeitlicher Bandpassfilter angewendet. Dieser wird so gewählt, dass nur der Frequenz-

³³Vgl. LEE, R. J./ SIVAKUMAR, S./ LIM, K. H. (2023), S. 44704

³⁴Vgl. WU, H.-Y. u. a. S. 1–3

³⁵Vgl. WU, H.-Y. u. a. S. 2–3

bereich der gesuchten zeitlichen Veränderung erhalten bleibt. Für pulssynchrone Veränderungen verwenden Wu et al. beispielsweise einen Bereich von 0,4 bis 4 Hz, was 24 bis 240 Herzschlägen pro Minute entspricht.

3. **Signalverstärkung:** Das zeitlich gefilterte Signal wird mit einem Verstärkungsfaktor α multipliziert. Dadurch werden die zuvor kaum sichtbaren Farb- oder Bewegungsänderungen im jeweiligen Frequenzbereich verstärkt.
4. **Rekonstruktion:** Abschließend werden die verstärkten Signalanteile wieder zum ursprünglichen Bildsignal addiert und die Pyramide rekonstruiert. Daraus entsteht das finale Ausgabevideo, in dem die zuvor subtilen Veränderungen sichtbar hervortreten.

Mathematische Begründung durch die Taylor-Reihe

Um zu erklären, unter welchen Annahmen eine zeitliche Filterung und Verstärkung von Pixelintensitäten näherungsweise einer räumlichen Bewegungsverstärkung entspricht, nutzt die EVM eine Taylor-Reihenentwicklung erster Ordnung.³⁶

Betrachtet man ein eindimensionales Bildsignal $I(x, t)$ an der Position x zur Zeit t , das einer kleinen translatorischen Verschiebung $\delta(t)$ unterliegt, lässt sich dies als $I(x, t) = f(x + \delta(t))$ ausdrücken. Eine Näherung durch die Taylor-Reihe ergibt:

$$I(x, t) \approx f(x) + \delta(t) \frac{\partial f(x)}{\partial x} \quad (2.7)$$

Wird nun ein zeitlicher Bandpassfilter auf $I(x, t)$ angewendet, extrahiert dieser die zeitliche Variation (unter Ausschluss des statischen Bildes $f(x)$). Das resultierende Signal $B(x, t)$ ist somit:

$$B(x, t) = \delta(t) \frac{\partial f(x)}{\partial x} \quad (2.8)$$

In der EVM-Pipeline wird dieses Signal mit dem Faktor α verstärkt und wieder zum ursprüng-

³⁶Vgl. Wu, H.-Y. u. a. S. 3

lichen Bild addiert. Das verarbeitete Signal $\tilde{I}(x, t)$ ergibt sich als:

$$\tilde{I}(x, t) = I(x, t) + \alpha B(x, t) \approx f(x) + (1 + \alpha)\delta(t) \frac{\partial f(x)}{\partial x} \quad (2.9)$$

Unter der Annahme, dass die Taylor-Näherung auch für die größere Verschiebung gültig bleibt, entspricht dies exakt dem originalen Signal, welches nun um den Faktor $(1 + \alpha)$ verschoben wurde:

$$\tilde{I}(x, t) \approx f(x + (1 + \alpha)\delta(t)) \quad (2.10)$$

Diese Herleitung zeigt den Kerngedanken der EVM unter den genannten Annahmen: Durch die zeitliche Filterung und Verstärkung von Pixelintensitäten können kleine Hautfarbänderungen durch den Blutfluss sowie kleine Bewegungen näherungsweise verstärkt werden. Die Gültigkeit dieser Interpretation ist jedoch auf kleine Verschiebungen, geeignete räumliche Frequenzbereiche und begrenzte Verstärkungsfaktoren beschränkt.³⁷

Grenzen der Verstärkung

Die Herleitung der EVM mittels der Taylor-Reihe basiert auf der Prämisse, dass es sich um kleine translatorische Verschiebungen handelt. Für Signale mit hohen räumlichen Frequenzen (z. B. scharfe Kanten im Bild) oder bei der Wahl eines zu großen Verstärkungsfaktors α verliert die Näherung erster Ordnung ihre Gültigkeit.³⁸

Um die mathematischen Grenzen der Verstärkung zu definieren, betrachten Wu et al. ein räumliches Kosinussignal $f(x) = \cos(\omega x)$ mit der räumlichen Frequenz ω ³⁹. Damit die Taylor-Näherung für das verstärkte Signal intakt bleibt, wird abgeleitet, dass die Kleinwinkelnäherung erfüllt sein muss. Daraus ergibt sich folgende Bedingung für den maximalen Verstärkungsfaktor in Abhängigkeit von der räumlichen Wellenlänge $\lambda = \frac{2\pi}{\omega}$ der Bewegung⁴⁰:

³⁷Vgl. Wu, H.-Y. u. a. S. 3–4

³⁸Vgl. Wu, H.-Y. u. a. S. 3

³⁹Vgl. Wu, H.-Y. u. a.

⁴⁰Vgl. Wu, H.-Y. u. a. S. 4

$$(1 + \alpha)\delta(t) < \frac{\lambda}{8} \quad (2.11)$$

Diese Gleichung stellt eine wesentliche Einschränkung für die praktische Anwendung der EVM dar: Bei hohen räumlichen Frequenzen, also kleinen Wellenlängen λ , muss der Verstärkungsfaktor α reduziert werden, um sichtbare Artefakte im Ausgabevideo zu vermeiden. Dadurch wird auch die räumliche Zerlegung der EVM-Pipeline begründet, da unterschiedliche Frequenzbänder unterschiedlich stark verstärkt werden können.⁴¹

2.3.3 Video-Ballistokardiographie (vBCG)

Die Video-Ballistokardiographie (vBCG) ist ein kamerabasiertes Verfahren zur kontaktlosen Erfassung pulssynchroner Mikrobewegungen des Körpers. Während die Remote-Photoplethysmographie (rPPG) optische Farbänderungen der Haut auswertet, basiert die vBCG auf mechanischen Bewegungen, die durch die Herzaktion und den Blutfluss im Körper entstehen.⁴²

Physiologischer Mechanismus

Der ballistokardiographische Effekt beruht auf dem Rückstoßprinzip nach dem dritten Newtonschen Gesetz. Mit jedem Herzschlag wird Blut aus der linken Herzkammer in die Aorta ausgeworfen. Die dabei entstehenden Kräfte und Blutdruckgradienten führen zu sehr kleinen, periodischen Bewegungen des Körpers.⁴³ Da Blut über die Halsschlagadern in Richtung Kopf transportiert wird, treten auch am Kopf pulssynchrone Mikrobewegungen auf. Diese Bewegungen können bei geeigneten Aufnahmebedingungen aus dem Videomaterial extrahiert und zur Schätzung der Pulsfrequenz genutzt werden.⁴⁴

Kim et al. modellieren die ballistokardiographische Kraft $F_{BCG}(t)$ als Folge von Blutdruck-

⁴¹Vgl. WU, H.-Y. u. a. S. 4

⁴²Vgl. BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. (2013), S. 3430

⁴³Vgl. KIM, C.-S. u. a. (2016), S. 1

⁴⁴Vgl. BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. (2013), S. 3430

gradienten in der aufsteigenden und absteigenden Aorta.⁴⁵

$$F_{BCG}(t) = A_D[P_1(t) - P_2(t)] - A_A[P_0(t) - P_1(t)] \quad (2.12)$$

Hierbei beschreiben A_A und A_D die Querschnittsflächen der aufsteigenden und absteigenden Aorta. $P_0(t)$ bezeichnet den Blutdruck am Eingang der aufsteigenden Aorta, $P_1(t)$ den Blutdruck am Übergang beziehungsweise Ausgang der aufsteigenden Aorta und $P_2(t)$ den Blutdruck am Ausgang der absteigenden Aorta. Das Modell führt die Entstehung der BCG-Wellen damit vor allem auf Druckgradienten in der aufsteigenden und absteigenden Aorta zurück.⁴⁶

Die daraus resultierenden Bewegungen sind sehr klein. Balakrishnan et al. beschreiben, dass die unwillkürliche vertikale Kopfbewegung nur eine geringe Beschleunigung aufweist und im Millimeterbereich liegt.⁴⁷ Obwohl diese Bewegung für das menschliche Auge kaum wahrnehmbar ist, kann sie aus Videomaterial extrahiert werden, sofern der Kopf ausreichend stabil erfasst wird.

Bildverarbeitungsansatz

Im Unterschied zur EVM, bei der zeitliche Änderungen an festen Bildpositionen verstärkt werden, wertet die vBCG die Bewegung konkreter Bildmerkmale am Kopf aus. Dazu werden zunächst markante Punkte im Kopf- oder Gesichtsbereich detektiert und anschließend über mehrere Frames hinweg verfolgt. Aus den entstehenden Trajektorien wird ein zeitliches Bewegungssignal abgeleitet, das pulssynchrone Bewegungsanteile enthalten kann.⁴⁸

Für die Pulsmessung ist insbesondere die vertikale Bewegungskomponente relevant. Balakrishnan et al. beschreiben, dass horizontale Bewegungen stärker durch Gleichgewichts- und Haltungsschwankungen beeinflusst werden, während die vertikale Komponente besser

⁴⁵Vgl. KIM, C.-S. u. a. (2016), S. 1

⁴⁶Vgl. KIM, C.-S. u. a. (2016), S. 2

⁴⁷Vgl. BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. (2013), S. 3431

⁴⁸Vgl. BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. (2013), S. 3430

geeignet ist, um pulssynchrone Kopfbewegungen zu erfassen.⁴⁹

Die vBCG-Verarbeitungspipeline

Die von Balakrishnan et al. vorgestellte Pipeline zur Extraktion dieser Bewegung lässt sich in folgende Schritte unterteilen:⁵⁰

Die von Balakrishnan et al. vorgestellte Pipeline zur pulsbasierten Auswertung von Kopfbewegungen besteht aus mehreren Verarbeitungsschritten:⁵¹

1. **Feature Tracking:** Zunächst wird der Kopf beziehungsweise das Gesicht im Video lokalisiert. Anschließend werden stabile Bildmerkmale detektiert und deren Positionen über die Zeit verfolgt, beispielsweise mit dem Lucas-Kanade-Tracker. Dadurch entstehen Trajektorien, welche die Bewegung der einzelnen Merkmale von Frame zu Frame beschreiben.⁵²
2. **Zeitliche Filterung:** Die erfassten Bewegungen enthalten neben dem Pulssignal auch andere Bewegungsanteile, etwa durch Atmung, Haltungsschwankungen oder unbewusste Kopfbewegungen. Deshalb werden die Bewegungssignale zeitlich gefiltert. Balakrishnan et al. verwenden hierfür einen Bandpassfilter im Bereich von 0,75 bis 5 Hz, um langsamere Bewegungsanteile, insbesondere durch Atmung, zu reduzieren.⁵³
3. **PCA-Dekomposition:** Da die gefilterten Trajektorien weiterhin eine Mischung verschiedener Bewegungsquellen enthalten, wird eine Hauptkomponentenanalyse (Principal Component Analysis, PCA) eingesetzt. Betrachtet man die vertikalen Positionen von N Feature-Points zum Zeitpunkt t als Vektor $m_t = [y_1(t), y_2(t), \dots, y_N(t)]$, kann daraus die Kovarianzmatrix Σ_m der Bewegungen berechnet werden. Die PCA bestimmt anschließend die Hauptbewegungsrichtungen als Eigenvektoren Φ_m dieser

⁴⁹Vgl. BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. (2013), S. 3431

⁵⁰Vgl. BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. (2013),

⁵¹Vgl. BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. (2013), S. 3432–3433

⁵²Vgl. BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. (2013), S. 3432

⁵³Vgl. BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. (2013), S. 3432

Matrix:⁵⁴

$$\Sigma_m \Phi_m = \Phi_m \Lambda_m \quad (2.13)$$

Dabei enthält Λ_m die zugehörigen Eigenwerte. Die ursprünglichen Zeitreihen werden anschließend auf die gefundenen Eigenvektoren ϕ_i projiziert, um eindimensionale Bewegungssignale $s_i(t)$ zu erhalten:⁵⁵

$$s_i(t) = \begin{pmatrix} m_1 \\ m_2 \\ \vdots \\ m_T \end{pmatrix} \cdot \phi_i \quad (2.14)$$

Dasjenige Signal, dessen Frequenzspektrum am besten zu einem plausiblen Herzfrequenzbereich passt, wird als pulssynchrones Bewegungssignal ausgewählt.

4. **Pulsberechnung (Peak Detection):** Aus dem ausgewählten vBCG-Signal kann anschließend die Herzfrequenz berechnet werden. Dies geschieht entweder über die dominante Frequenz im Frequenzspektrum oder über Peak-Detection im Zeitbereich. Bei der Peak-Detection werden lokale Maxima des Bewegungssignals als einzelne Herzschläge interpretiert, sodass aus den zeitlichen Abständen die Pulsfrequenz bestimmt werden kann.⁵⁶

Ein Vorteil der vBCG gegenüber der rPPG besteht darin, dass keine direkte, unbedeckte Sicht auf Hautregionen erforderlich ist. Da die Methode mechanische Kopfbewegungen auswertet, kann sie grundsätzlich auch dann funktionieren, wenn Hautbereiche nur teilweise sichtbar sind oder die Beleuchtungsbedingungen ungünstig sind.⁵⁷

⁵⁴Vgl. BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. (2013), S. 3433

⁵⁵Vgl. BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. (2013), S. 3433

⁵⁶Vgl. BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. (2013), S. 3433–3434

⁵⁷Vgl. BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. (2013), S. 3430

2.4 Emotionserkennung mittels Gesichtsanalyse

Neben der kontaktlosen Pulsfrequenzmessung lassen sich mit einer Kamera auch Gesichtsausdrücke auswerten, die Hinweise auf den emotionalen Zustand einer Person geben können. Ziel ist dabei, aus Kamerabildern Merkmale des aktuellen Gesichtsausdrucks abzuleiten.

Grundsätzlich lassen sich mehrklassige Verfahren, bei denen mehrere Gesichtsausdrücke beziehungsweise Emotionsklassen erkannt werden, von einfachen binären Ansätzen unterscheiden. Bei binären Ansätzen wird lediglich ein bestimmtes Ausdrucksmerkmal erkannt, ohne dass mehrere Emotionen unterschieden werden. Ein Beispiel hierfür ist die Smile-Detection, bei der zwischen einem erkannten und einem nicht erkannten Lächeln unterschieden wird.⁵⁸ Solche Ansätze können für ressourcenbeschränkte Echtzeitsysteme geeignet sein, da klassische Verfahren wie Haar-Cascades besonders schnell und einfach in Videostreams einsetzbar sind.⁵⁹

2.4.1 Bildvorverarbeitung und Gesichtserkennung

Die technische Grundlage der Gesichtsanalyse bildet die Verarbeitung einzelner Kamerabilder. Das Farbbild der Kamera wird für die weitere Analyse in ein Graustufenbild umgewandelt. Eine solche Vorverarbeitung wird auch in der von OpenCV dokumentierten Cascade-Classifizier-Pipeline zur Objekt- beziehungsweise Gesichtserkennung verwendet.⁶⁰

Für Haar-Cascades ist diese Darstellung geeignet, da sie auf sogenannten Haar-like Features basieren. Dabei handelt es sich um rechteckige Merkmale, bei denen die Summe der Pixelwerte in hellen und dunklen Bereichen miteinander verglichen wird. Ein Feature ergibt sich dabei aus der Differenz zwischen der Pixelsumme unter dem weißen Rechteck und der Pixelsumme unter dem schwarzen Rechteck. Solche Merkmale können Kontrastunterschie-

⁵⁸Vgl. ROSEBROCK, A. (2021),

⁵⁹Vgl. ROSEBROCK, A. (2021),

⁶⁰Vgl.

de im Gesicht erfassen. Beispielsweise sind Augenregionen häufig dunkler als Nasen- oder Wangenbereiche.⁶¹




Abbildung 2: Haar-like Features und ihre Anwendung auf Gesichtsbereiche.⁶²

Aus den berechneten Haar-like Features wird durch ein trainiertes Klassifikationsmodell entschieden, ob ein Bildausschnitt ein Gesicht enthält oder nicht. Der Cascade-Classifier arbeitet dabei stufenweise. Bildbereiche, die bereits in frühen Stufen nicht zu einem Gesicht passen, werden verworfen. Nur vielversprechende Bereiche werden an weitere Stufen weitergegeben. Dadurch muss nicht jeder Bildausschnitt vollständig mit allen Merkmalen ausgewertet werden, was die Erkennung beschleunigt und den Einsatz in Videostreams ermöglicht.⁶³

Wird ein Gesicht erkannt, kann der entsprechende Bildbereich als ROI extrahiert werden. Die nachfolgende Analyse wird dadurch auf den relevanten Gesichtsbereich beschränkt, statt das gesamte Kamerabild auszuwerten.

2.4.2 Smile-Detection als binäre Gesichtsausdruckserkennung

Auf Basis der extrahierten Gesichts-ROI kann anschließend eine Smile-Detection durchgeführt werden. In OpenCV-basierten Smile-Detection-Pipelines wird die Gesichts-ROI einem

⁶¹Vgl.

⁶³Vgl.

Klassifikator übergeben, der zwischen »smiling« und »not smiling« unterscheidet.⁶⁴

Die Smile-Detection stellt damit eine binäre Form der Gesichtsausdruckserkennung dar. Sie reduziert die Analyse auf ein einzelnes sichtbares Ausdrucksmerkmal, nämlich das Vorhandensein eines Lächelns. Im Gegensatz zu mehrklassigen Verfahren, die mehrere Emotionsklassen wie Freude, Trauer, Wut oder Überraschung unterscheiden, liefert dieser Ansatz lediglich eine Aussage darüber, ob ein Lächeln erkannt wurde oder nicht.

2.5 Hardwarekomponenten

2.6 3D Druck

⁶⁴Vgl. ROSEBROCK, A. (2021),

3. Durchführung

3.1 Anforderungsanalyse

3.2 Algorithmische Konzeption

4. Implementierung

4.1 Hardwareaufbau

4.2 Softwareimplementierung

4.2.1 rPPG-Modul (Signalextraktion, Filter, Herzfrequenzberechnung)

4.2.2 Emotionserkennungsmodell (Pipeline, Modellwahl, Inferenz)

4.2.3 Backend-Logik

4.2.4 Frontend

4.3 Integration & Systemtests

5. Evaluation und Ergebnisse

5.1 Testmethodik

5.2 Messgenauigkeit rPPG

5.3 Leistung der Emotionserkennung

5.4 Performance des Gesamtsystems

5.5 Diskussion

6. Zusammenfassung und Ausblick

Anhang

Anhangsverzeichnis

Literaturverzeichnis

BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J. Juni 2013. »Detecting Pulse from Head Motions in Video«. In: *2013 IEEE Conference on Computer Vision and Pattern Recognition*.

BALAKRISHNAN, G./ DURAND, F./ GUTTAG, J.: »Detecting Pulse from Head Motions in Video«, IEEE, 2013, S. 3430–3437. Besucht am 08. 04. 2026.

Cascade Classifier, o.J., Einsichtnahme:

FU, K. u. a. o. D. »Safety, Security, and Privacy Threats Posed by Accelerating Trends in the Internet of Things«. In:

KIM, C.-S. u. a. Aug. 2016. »Ballistocardiogram: Mechanism and Potential for Unobtrusive Cardiovascular Health Monitoring«. In: *Scientific Reports* 6.1, S. 31297. ISSN: 2045-2322. Besucht am 13. 04. 2026.

LEE, R. J./ SIVAKUMAR, S./ LIM, K. H. Okt. 2023. »Review on Remote Heart Rate Measurements Using Photoplethysmography«. In: *Multimedia Tools and Applications* 83.15, S. 44699–44728. ISSN: 1573-7721. Besucht am 13. 04. 2026.

PFNÜR, A. u. a.: *So Wohnen Wir in Zukunft: Wie Die Digitalisierung Das Wohnen Verändert–Empirische Studie Bei Privaten Haushalten*, 2023.

ROSEBROCK, A.: *OpenCV Haar Cascades*, 2021, Einsichtnahme:

ROSEBROCK, A.: *Smile Detection with OpenCV, Keras, and TensorFlow*, 2021, Einsichtnahme:

SHEI, R.-J. u. a. Sep. 2022. »Wearable Activity Trackers–Advanced Technology or Advanced Marketing?«. In: *European Journal of Applied Physiology* 122.9, S. 1975–1990. ISSN: 1439-6319, 1439-6327. Besucht am 19. 02. 2026.

VERKRUYSSSE, W./ SVAASAND, L. O./ NELSON, J. S. Dez. 2008. »Remote Plethysmographic Imaging Using Ambient Light«. In: *Optics Express* 16.26, S. 21434. ISSN: 1094-4087. Besucht am 09. 04. 2026.

WANG, W. u. a. Juli 2017. »Algorithmic Principles of Remote PPG«. In: *IEEE Transactions on Biomedical Engineering* 64.7, S. 1479–1491. ISSN: 0018-9294, 1558-2531. Besucht am 08.04.2026.

WU, H.-Y. u. a. o. D. »Eulerian Video Magnification for Revealing Subtle Changes in the World«. In: